

Sistema Inteligente de Predicción y Explicación de Riesgo de Deserción Universitaria

Machine Learning, explicabilidad con SHAP y recomendaciones generadas con OpenAI

Jose Luis Restrepo Tamayo Samuel Cadavid Zapata
jlrestrept@eafit.edu.co scadavidz@eafit.edu.co

Juan Jose Restrepo
jjrestrepc@eafit.edu.co

Escuela de Ciencias Aplicadas e Ingeniería · Universidad EAFIT

Curso: Inteligencia Artificial · Semestre 2026-1

Entrega: 19–22 de mayo de 2026

Repositorio: https://github.com/jose1uis/PROYECTO_FINAL_INT_ARTIFICIAL2026.git

Resumen

Contexto: La deserción universitaria afecta la permanencia estudiantil, la planeación institucional y el bienestar de los estudiantes. **Objetivo:** construir un sistema de alerta temprana que estime el riesgo de deserción y explique los factores principales de cada predicción. **Método:** se usó el dataset *Predict Students' Dropout and Academic Success* de UCI, un pipeline de preprocesamiento, un modelo Random Forest, explicabilidad con SHAP e integración con OpenAI para generar recomendaciones en lenguaje natural. **Resultados:** el modelo obtuvo $AUC-ROC = 0.928$, $F1 = 0.800$ y $recall = 0.796$ en el conjunto de prueba. **Conclusión:** el sistema muestra que un enfoque combinado de ML explicable y LLM puede apoyar intervenciones académicas tempranas, siempre como herramienta de apoyo y no como sustituto del criterio humano.

Palabras clave: Machine Learning, deserción estudiantil, Random Forest, SHAP, OpenAI, Streamlit, EDA.

1. Introducción

La deserción estudiantil es un problema relevante para universidades porque reduce la continuidad académica, incrementa costos institucionales y puede reflejar barreras económicas, académicas o personales. El proyecto plantea la pregunta de investigación: ¿puede un modelo de Machine Learning predecir estudiantes en riesgo de deserción con una $AUC-ROC$ superior a 0.85 y generar explicaciones comprensibles para apoyar decisiones de acompañamiento?

El sistema usa un dataset público de UCI con información académica, demográfica y socioeconómica de estudiantes de educación superior. El documento presenta la exploración de datos, arquitectura, metodología experimental, resultados, limitaciones y conclusiones del sistema implementado.

2. Datos y Exploración (EDA)

2.1. Descripción del dataset


Tabla 1: Resumen del dataset utilizado

Atributo	Descripción
Fuente	UCI Machine Learning Repository, dataset 697
Registros (N)	4.424 estudiantes
Features (p)	36 variables predictoras
Variable objetivo	Target: Dropout, Enrolled, Graduate. Para este proyecto se binariza Dropout vs. resto.
Tipo de problema	Clasificación binaria para detección de riesgo de deserción
Licencia	Creative Commons Attribution 4.0 International (CC BY 4.0)

2.2. Hallazgos del análisis exploratorio

El dataset contiene tres estados académicos: **Graduate**, **Dropout** y **Enrolled**. La clase **Dropout** representa 1.421 de 4.424 registros, aproximadamente 32,1% de los casos. Aunque no es un desbalance extremo, la métrica accuracy puede ocultar errores importantes; por eso se reportan F1, recall y AUC-ROC.

Las variables con mayor importancia están relacionadas con el desempeño curricular de primer y segundo semestre, el pago oportuno de matrícula, edad de ingreso, condición de deudor y beca. Esto sugiere que el riesgo de deserción combina señales académicas y socioeconómicas.

**Figura 1:** Distribución de la variable objetivo en el dataset UCI.

3. Arquitectura del Sistema

La arquitectura implementada integra carga de datos, preprocesamiento reproducible, entrenamiento de modelo, explicabilidad local y generación de recomendaciones. La interfaz Streamlit permite cargar un CSV, seleccionar la variable objetivo, visualizar métricas, revisar explicaciones y generar una recomendación usando la API de OpenAI.




Figura 2: Arquitectura general del sistema propuesto.

3.1. Componentes principales

Preprocesamiento. Se usa imputación por mediana para variables numéricas, imputación por moda para variables categóricas, estandarización numérica y One-Hot Encoding para categorías.

Modelo de ML. El modelo principal es Random Forest con 300 árboles, profundidad máxima 8, `min_samples_leaf = 5` y `class_weight = balanced`. Este modelo es apropiado para datos tabulares mixtos y permite calcular importancia de variables.

Componente LLM. OpenAI se usa para convertir la probabilidad de riesgo y los factores explicativos en recomendaciones en lenguaje natural. La estrategia de prompting es zero-shot con instrucciones de cautela, claridad y no invención de datos.

Interfaz. La aplicación se construyó en Streamlit e incluye pestañas para datos, evaluación del modelo y análisis individual de estudiantes.

4. Metodología

4.1. Configuración experimental

Tabla 2: Hiperparámetros y configuración de entrenamiento

Parámetro	Valor
Framework	scikit-learn, pandas, Streamlit, SHAP, OpenAI API
División	80 % entrenamiento / 20 % prueba
Random state	42
Modelo principal	<code>RandomForestClassifier</code>
Número de árboles	300
Profundidad máxima	8
Balance de clases	<code>class_weight = balanced</code>
Hardware	CPU local

4.2. Estrategia de validación

Se usó hold-out estratificado con 80 % de los registros para entrenamiento y 20 % para prueba, manteniendo la proporción de casos **Dropout**. El split se realiza antes del preprocesamiento para evitar *data leakage*; los parámetros de imputación, escalado y codificación se aprenden solamente con el conjunto de entrenamiento dentro de un Pipeline.

4.3. Experimentos realizados

1. **Baseline:** Regresión Logística balanceada como modelo interpretable de referencia.
2. **Experimento principal:** Random Forest balanceado para capturar relaciones no lineales entre variables académicas, demográficas y socioeconómicas.
3. **Integración explicativa:** generación de factores principales por importancia local y recomendación textual mediante OpenAI.

5. Resultados

5.1. Métricas de evaluación

Tabla 3: Comparación de modelos en test set

Modelo	Accuracy	Precision	Recall	F1	AUC-ROC
Baseline (Regresión Logística)	0.873	0.787	0.831	0.808	0.927
Random Forest (mejor)	0.872	0.804	0.796	0.800	0.928

Tabla 4: Matriz de confusión del modelo Random Forest

	Pred: no riesgo	Pred: riesgo
Real: no riesgo	546	55
Real: riesgo	58	226




Figura 3: Variables más importantes del modelo Random Forest.

5.2. Análisis cualitativo

Para un estudiante individual, el sistema calcula la probabilidad de deserción, identifica los factores con mayor contribución y genera una recomendación. Ejemplo de salida esperada: riesgo alto; los factores principales están asociados con bajo número de unidades curriculares aprobadas, calificaciones bajas en segundo semestre y matrícula no al día. La recomendación sugiere acompañamiento académico, revisión de apoyo financiero y seguimiento desde bienestar universitario.

6. Discusión

6.1. Interpretación de resultados

El Random Forest obtuvo AUC-ROC de 0.928, lo que indica buena separación entre estudiantes con y sin riesgo de deserción. El F1 de 0.800 y el recall de 0.796 muestran que el sistema identifica una proporción importante de casos **Dropout** sin sacrificar demasiado la precisión.

Las variables más influyentes corresponden principalmente al desempeño curricular de los primeros semestres. Esto es coherente con la hipótesis de que el rendimiento temprano y las condiciones financieras son señales útiles para intervenciones preventivas.

6.2. Limitaciones

- El dataset proviene de un contexto institucional específico; por tanto, el modelo puede no generalizar directamente a otras universidades sin recalibración.
- La variable **Enrolled** fue agrupada como no deserción para formular el problema binario, lo cual simplifica una realidad académica más compleja.
- Las recomendaciones del LLM dependen de los datos enviados por el sistema y no deben usarse para tomar decisiones automáticas sobre estudiantes.

6.3. Trabajo futuro

- Evaluar modelos adicionales como XGBoost o LightGBM y realizar búsqueda de hiperparámetros con validación cruzada estratificada.
- Incorporar datos longitudinales de asistencia, uso de plataformas académicas y alertas tempranas por periodo.
- Validar las recomendaciones con expertos de bienestar universitario para mejorar utilidad, tono y responsabilidad.

7. Conclusiones

El proyecto demuestra que es posible construir un sistema de alerta temprana de deserción con datos tabulares, Machine Learning explicable e integración con modelos de lenguaje. La pregunta de investigación se responde positivamente: el modelo principal superó el umbral propuesto de AUC-ROC 0.85 al alcanzar 0.928. La combinación de Random Forest, explicabilidad y recomendaciones generadas con OpenAI facilita que usuarios no técnicos comprendan los factores de riesgo y posibles acciones de acompañamiento.

Contribuciones del equipo

Integrante	Contribución principal
Juan Jose Restrepo	EDA, preprocesamiento y visualizaciones
Jose Luis Restrepo	Arquitectura del modelo y entrenamiento
Jose Luis Restrepo	Integración OpenAI, explicabilidad y Streamlit
Samuel Cadavid	Evaluación, análisis e informe final

Repositorio y Demo

- GitHub: https://github.com/jose1uis/PROYECTO_FINAL_INT_ARTIFICIAL2026.git
- Video demo (máx. 3 min): <https://youtu.be/hj7ExfjDvVw>
- Instalación: `pip install -r requirements.txt`
- Ejecución: `streamlit run app.py`

Referencias

1. UCI Machine Learning Repository. (2021). *Predict Students' Dropout and Academic Success*. <https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success>
2. Breiman, L. (2001). Random forests. *Machine Learning*, 45, 5–32.
3. Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*.
4. OpenAI. (2026). *OpenAI API documentation*. <https://platform.openai.com/docs>
5. Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

A. Detalles de hiperparámetros y búsqueda

La primera versión usa hiperparámetros fijos para mantener reproducibilidad. Como extensión, se recomienda GridSearchCV o RandomizedSearchCV sobre `n_estimators`, `max_depth`, `min_samples_leaf` y `max_features`.

B. Ejemplos adicionales de outputs del sistema

Ejemplo: probabilidad estimada de deserción 72 %. Factores principales: pocas unidades curriculares aprobadas, baja nota de segundo semestre y deuda. Recomendación: priorizar reunión con consejería académica, revisar plan de financiación y crear seguimiento de progreso durante las próximas cuatro semanas.